TEMA N° 7

I. INFORMACIÓN GENERAL:

Nombre del curso: Base de Datos Avanzada y Big Data
Nombre del tema: Ecosistema Big Data y análisis con Spark

Título de la experiencia de laboratorio: Procesamiento Distribuido y Análisis Estadístico Masivo con Apache Spark

II. OBJETIVO:

Analizar grandes volúmenes de datos mediante la arquitectura de Apache Spark para implementar soluciones de procesamiento distribuido y visualización de resultados estratégicos.

III. FUNDAMENTO TEÓRICO

- **Ecosistema Big Data:** Conjunto de tecnologías diseñadas para gestionar las "V" del Big Data (Volumen, Velocidad, Variedad, Veracidad y Valor). La arquitectura distribuida permite procesar datos en clústeres de servidores.
- **Apache Spark:** Motor de procesamiento unificado de código abierto para el análisis de datos a gran escala.
    - **RDD (Resilient Distributed Datasets):** Colección de objetos tolerante a fallos que se puede operar en paralelo.
    - **DataFrames:** Colección distribuida de datos organizados en columnas con nombre, similar a una tabla relacional.
    - **Spark SQL:** Módulo de Spark para el procesamiento de datos estructurados mediante sintaxis SQL.
- **Estadística Avanzada en Big Data:** Aplicación de modelos descriptivos y predictivos sobre datasets que superan la capacidad de las bases de datos relacionales convencionales.

IV. HERRAMIENTAS, SIMULADORES Y/O RECURSOS

Lista de la plataforma, programa, simulador y/o recursos digitales necesarios para la experiencia

N°	Herramienta / Simuladores y/o Recurso Virtual	Uso o función específica	Acceso / Enlace
1	SQL Server Management Studio (SSMS)	Entorno de administración y desarrollo SQL.	Microsoft SSMS
2	Apache Spark (PySpark/Scala)	Motor de procesamiento distribuido y análisis de datos.	Spark
3	Visual Studio con Extensiones BI	Entorno de desarrollo para proyectos de Integration Services (SSIS).	Visual Studio
4	SQL Server Reporting Services / Report Builder	Generación de reportes paginados y operativos.	Report Builder
5	Power BI Desktop	Diseño de dashboards interactivos y visualización de KPIs.	Power BI Desktop

V. PROCEDIMIENTO

1. **Inicialización del Entorno y Carga de Datos**
   Para trabajar con Spark, es necesario configurar la sesión. Spark permite leer datos desde SQL Server mediante conectores JDBC.

   - **Explicación:** Se define la SparkSession y se cargan los datos en un DataFrame para su manipulación.
   - **Código de ejemplo:**

```python
# Ejemplo: Configuración de sesión y lectura
from pyspark.sql import SparkSession

spark = SparkSession.builder.appName("LaboratorioBigData").getOrCreate()

# Carga de datos desde una fuente CSV o Parquet
df_playas = spark.read.format("csv").option("header", "true").load("limpieza_play
```

2. **Manipulación con Spark SQL y DataFrames**
   Spark SQL permite ejecutar consultas complejas sobre datos masivos con un rendimiento optimizado.

   - **Explicación:** Se registra el DataFrame como una vista temporal para aplicar lógica SQL estándar sobre el ecosistema distribuido.

   - **Código de ejemplo:**

```python
# Ejemplo: Filtrado y agregación estadística
df_playas.createOrReplaceTempView("playas")

resultado = spark.sql("""
    SELECT region, AVG(toneladas_recogidas) as promedio, COUNT(*) as voluntarios
    FROM playas
    GROUP BY region
    HAVING promedio > 2.5
""")
resultado.show()
```

3. **Integración para Visualización**

    - **Explicación:** Una vez procesados los datos en Spark, los resultados refinados pueden exportarse a SQL Server para ser consumidos por Power BI, o conectarse directamente mediante Spark Thrift Server.

GUÍA PARA EL ESTUDIANTE

Caso Práctico: Organización "Ocean Clean-Up Peru"

La ONG "Ocean Clean-Up Peru" recolecta diariamente datos de sensores, voluntarios y registros históricos de limpieza en todo el litoral peruano. La cantidad de información (registros de microplásticos, peso de residuos, condiciones climáticas) ha crecido exponencialmente, requiriendo una migración a un ecosistema Big Data.

Prerrequisitos (Esquema de Base de Datos):

- **Playas:** PlayaID, Nombre, Region, Coordenadas.
- **Jornadas_Limpieza:** JornadaID, PlayaID, Fecha, NumVoluntarios, TemperaturaAmbiente.
- **Residuos_Detalle:** RegistroID, JornadaID, TipoResiduo (Plástico, Vidrio, Orgánico), PesoKg.
- **Sensores_Calidad:** SensorID, PlayaID, NivelContaminacion, Timestamp.

Requerimientos del caso:

1. **Ingesta de Datos:** Cargar los datasets históricos de residuos desde SQL Server a un DataFrame de Spark.
2. **Limpieza Masiva:** Identificar y eliminar registros duplicados en la tabla de Residuos_Detalle que superen los 10 millones de filas.
3. **Análisis por Región:** Calcular el total de toneladas recolectadas por cada región del país utilizando Spark SQL.
4. **Estadística de Voluntariado:** Obtener la desviación estándar y la media de voluntarios necesarios para recolectar 1 tonelada de plástico.
5. **Impacto Climático:** Correlacionar la TemperaturaAmbiente con el NivelContaminacion detectado por los sensores.
6. **Clasificación de Residuos:** Crear una nueva columna calculada que categorice las jornadas en "Alto Impacto" o "Bajo Impacto" según el peso recolectado.
7. **Optimización de Almacenamiento:** Exportar los resultados procesados en formato *Parquet* para mejorar la velocidad de lectura futura.
8. **Detección de Anomalías:** Identificar picos de contaminación inusuales (3 desviaciones estándar sobre la media) mediante funciones estadísticas de Spark.
9. **Dashboard Ejecutivo:** Conectar Power BI a los resultados de Spark para visualizar el ranking de las 5 playas más contaminadas.
10. **Gobernanza:** Implementar un filtro que anonimice los ID de los voluntarios en los reportes finales por motivos de privacidad.

I. DATOS EXPERIMENTALES O REGISTROS DE EJECUCIÓN

- ✓ **Registros:** Describir la cantidad de filas procesadas en cada DataFrame.
- ✓ **Evidencias:** Incluir capturas del plan de ejecución de Spark (DAG) y los resultados de las consultas SQL.
- ✓ **Tablas:** Presentar una tabla comparativa de tiempos de ejecución entre una consulta estándar en SQL Server vs Spark SQL para el dataset de residuos.

II. ANÁLISIS DE RESULTADOS

Responde a las siguientes preguntas de reflexión:

1. **Técnica:** ¿Cómo influye el particionamiento de datos en el rendimiento de Spark al procesar el historial de "Ocean Clean-Up"?
2. **Técnica:** ¿En qué casos un RDD es más eficiente que un DataFrame para el análisis de sensores de calidad de agua?
3. **Ética:** Si los datos muestran que ciertas empresas son las principales responsables de la contaminación, ¿cuál es la responsabilidad ética del Ingeniero de Datos al presentar estos resultados ante grupos de interés?
4. **Ética:** ¿Cómo garantizar que la recolección de datos mediante sensores en playas públicas no vulnere la privacidad de los ciudadanos que las visitan?

III. CONCLUSIONES:

Redactar entre 2 y 3 conclusiones que respondan al objetivo de aplicar Spark en el análisis masivo de datos. Las conclusiones deben basarse en los registros de ejecución obtenidos..