UPN, PASIÓN POR TRANSFORMAR VIDAS



TEMA 7: Ecosistema Big Data y análisis con Spark

Ing. Andres E. Araujo Acuña

Ruta de la Sesión

1. Fundamentos Big Data
Características del entorno y procesamiento distribuido frente al procesamiento local.

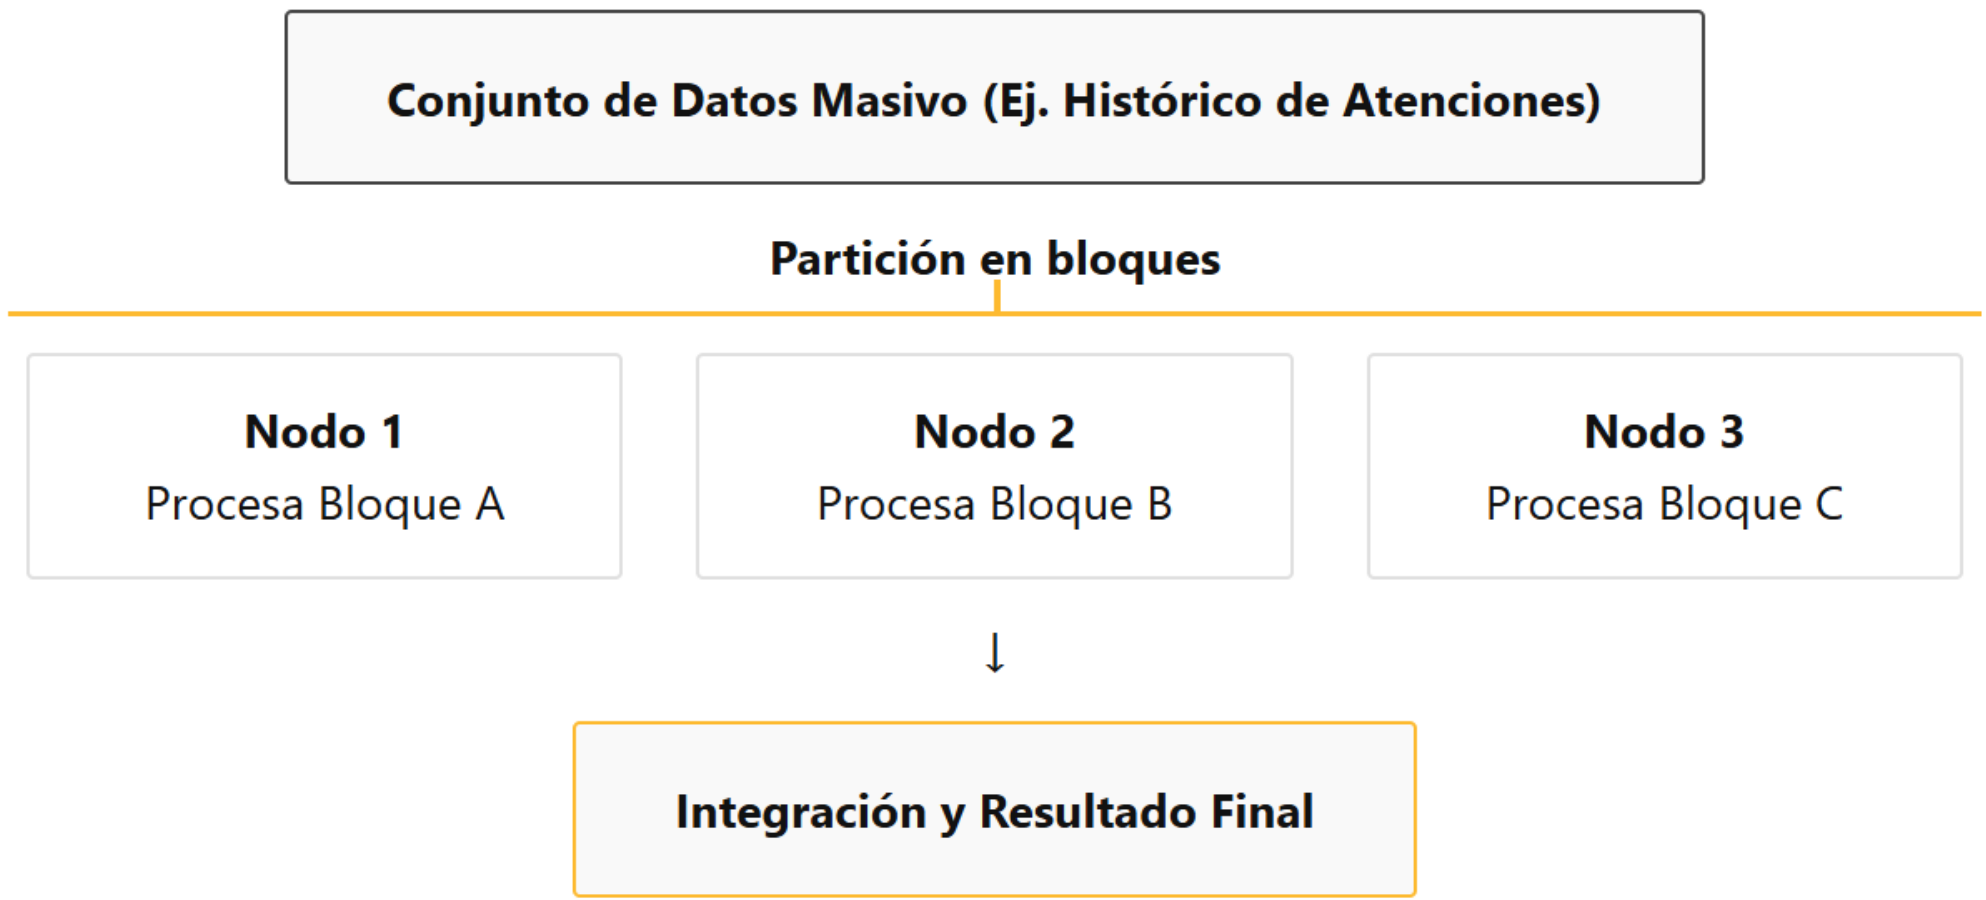
2. Ecosistema Apache Spark
Uso de RDD, DataFrames y SparkSQL para transformar y analizar información.

3. Análisis Masivo
Cálculo de estadísticas, agregaciones y operaciones analíticas sobre grandes volúmenes.

4. Rendimiento y Escalabilidad
Comparación práctica de tiempos de ejecución entre SQL Server y Spark.

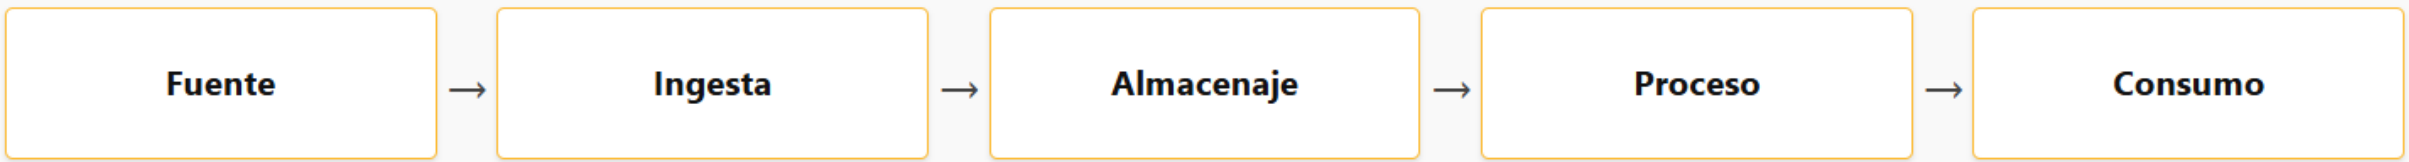
Procesamiento Local vs. Distribuido

En el modelo distribuido, el trabajo se divide en partes y se ejecuta en varios recursos de cómputo simultáneamente (escalamiento horizontal).



Actividad 1: Arquitectura Big Data

Analiza el flujo de datos de la DIRESA y completa los componentes de la arquitectura de referencia.



Componente	Función Principal	Ejemplo en DataSalud
Fuente	Origen donde se generan los datos	Sistemas SQL, Archivos CSV
Almacenamiento	Repositorio centralizado masivo	_____
Procesamiento	Motor de cálculo y transformación	_____
Consumo	Visualización y análisis para negocio	_____

Estructuras de Análisis en Apache Spark

RDD

Resilient Distributed Dataset

- Colección distribuida e inmutable.
- Evaluación perezosa.
- Control de bajo nivel mediante funciones lambda.

DataFrame

Estructura Tabular

- Organizado en filas y columnas (esquema).
- Optimizado internamente (Catalyst).
- Ideal para análisis estructurado y limpieza (ETL).

SparkSQL

Consultas Declarativas

- Uso de sintaxis SQL estándar.
- Requiere registrar vistas temporales.
- Facilita la transición desde bases relacionales.

Actividad 2: Configuración y DataFrames

Crea la sesión Spark y aplica transformaciones iniciales para definir el esquema correctamente.

```
from pyspark.sql import SparkSession
from pyspark.sql.functions import col, to_date

# 1. Inicializar la sesión
spark = (
    SparkSession.builder
    .appName("Tema07DataSalud")
    .master("_____") # Definir entorno de ejecución
    .getOrCreate()
)

# 2. Transformar tipo de dato
df = df.withColumn(
    "FechaAtencion",
    to_date(col("_____"), "yyyy-MM-dd")
)

df.printSchema()
df.show(5)
```

Pregunta: ¿Por qué es crítico asegurar el tipo Date antes de realizar agregaciones?

Actividad 3: Análisis Comparativo de APIs

Enfoque DataFrame API

Agrupación utilizando métodos encadenados.

```
from pyspark.sql.functions import count

resultado_df = (
    df.groupBy("Provincia")
      .agg(count("AtencionId").alias("Total"))
      .orderBy("Provincia")
)

resultado_df.show()
```

Enfoque SparkSQL

Completa la consulta utilizando sintaxis estándar.

```
# Registrar la vista
df.createOrReplaceTempView("atenciones")

resultado_sql = spark.sql("""
    SELECT
        Provincia,
        COUNT(*) AS Total
    FROM atenciones
    _______________
    _______________
""")

resultado_sql.show()
```

Actividad 4: Rendimiento SQL Server vs Spark

Ejecuta la misma agregación (Total de atenciones y duración promedio por Tipo) en ambos motores y registra la evidencia empírica.

Métrica de Rendimiento	SQL Server (Relacional)	Apache Spark (Distribuido)
Filas procesadas	_____	_____
Tiempo de ejecución (seg)	_____	_____
Tipo de ejecución	Servidor Centralizado	Memoria Distribuida / Local
Costo de Inicialización	Bajo (Conexión persistente)	_____

Identifica el sobrecosto de Spark: ¿Qué ocurre al iniciar la SparkSession y crear el plan de ejecución la primera vez?

Escalabilidad y Decisión Tecnológica

Spark no es un reemplazo de las bases de datos relacionales, sino un complemento para escenarios específicos.

¿Cuándo usar SQL Server?

- Volumen moderado estructurado.
- Necesidad de consultas interactivas rápidas.
- Transacciones y alta concurrencia.

¿Cuándo usar Apache Spark?

- Crecimiento masivo y escalamiento horizontal.
- Procesamiento de múltiples formatos (ETL pesado).
- Integración con analítica avanzada.

BIBLIOGRAFIA REFERENCIAL

- Universidad Privada del Norte. (s. f.). *Biblioteca Virtual UPN*. https://biblioteca.upn.edu.pe/

- Universidad Privada del Norte. (s. f.). *Sistema de inteligencia de negocios en la administración de cultivos para la producción agrícola*. Repositorio Institucional UPN. https://repositorio.upn.edu.pe/handle/11537/29607

- [Autor no identificado]. (2023). *Utilización de un marco de inteligencia de negocios y minería de datos como herramientas computacionales en las PYMES: Pronóstico de producción de una planta de energía hidroeléctrica como caso de estudio*. LACCEI. https://laccei.org/LACCEI2023-BuenosAires/meta/FP832.html


UPN
UNIVERSIDAD
PRIVADA
DEL NORTE